



Taller grupal

analítica de datos

Juan Felipe Rodríguez G. 20261595004
Carlos Stiven Mora Hoyos 20261595003
Sergio Santiago Duarte Rojas 20261595002

Curso: Analítica de datos

Universidad Distrital Francisco José de Caldas

Bogotá, Colombia
21 de mayo de 2026

Índice

1. Actividad 1: Backpropagation con función tangente hiperbólica	3
2. Actividad 2: Diferencias entre Naïve Bayes y red TAN	3
3. Actividad 3: Tolerancia al ruido en redes neuronales	3
4. Actividad 4: Heurísticas para la tasa de aprendizaje	3
4.1. Heurística 1: Decaimiento de la tasa de aprendizaje	3
4.2. Heurística 2: Tasa de aprendizaje adaptativa (escalamiento por coordenadas)	4
4.3. Heurística 3: Programación cíclica de la tasa de aprendizaje (CLR) . .	4
5. Actividad 5: Diagrama de dispersión y clustering	5
5.1. Principio de funcionamiento	5
5.2. Ejemplo ilustrativo	6
5.3. Uso del diagrama para seleccionar algoritmos	7
6. Actividad 6: Clustering para detección de anomalías	7
6.1. Fundamento teórico	7
6.2. Enfoque práctico: Clustering + umbral de distancia	8
6.3. Ventajas y limitaciones	8
7. Actividad 7: Métodos jerárquicos en análisis de grupos	9
8. Actividad 8: SOM (Kohonen) vs ART2	9
9. Actividad 9: Agrupación incremental	9
10. Actividad 10: Distancias de similitud para agrupación	10
Bibliografía	11

1. Actividad 1: Backpropagation con función tangente hiperbólica

Pendiente de completar

Reescriba el algoritmo backpropagation (retropropagación) utilizando una función de transferencia tipo tangente hiperbólica.

2. Actividad 2: Diferencias entre Naïve Bayes y red TAN

Pendiente de completar

Describa las diferencias entre la red naïve bayes y la red TAN (naïve bayes aumentado). Plantee un ejemplo para cada red.

3. Actividad 3: Tolerancia al ruido en redes neuronales

Pendiente de completar

¿Por qué se afirma que las redes neuronales artificiales son altamente tolerantes al ruido? Explique mediante un ejemplo.

4. Actividad 4: Heurísticas para la tasa de aprendizaje

La tasa de aprendizaje (η) es uno de los hiperparámetros más críticos en el entrenamiento de redes neuronales mediante retropropagación. Un valor excesivamente grande provoca oscilaciones y divergencia; uno demasiado pequeño ralentiza la convergencia o atrapa el optimizador en mínimos locales. A continuación se presentan tres heurísticas ampliamente adoptadas.

4.1. Heurística 1: Decaimiento de la tasa de aprendizaje

Consiste en reducir progresivamente η a medida que avanzan las épocas. La idea central es permitir pasos grandes al inicio (exploración rápida del espacio de pesos) y pasos pequeños al final (refinamiento cercano al óptimo).

Formulación matemática. Dos variantes clásicas son:

1. **Decaimiento exponencial:**

$$\eta(t) = \eta_0 \cdot e^{-\lambda t}, \quad (1)$$

donde η_0 es la tasa inicial, $\lambda > 0$ es la tasa de decaimiento y t es el número de época.

2. **Decaimiento por etapas (step decay):**

$$\eta(t) = \eta_0 \cdot \gamma^{\lfloor t/s \rfloor}, \quad (2)$$

donde $\gamma \in (0, 1)$ es el factor de reducción y s es el período (cada cuántas épocas se reduce la tasa).

4.2. Heurística 2: Tasa de aprendizaje adaptativa (escalamiento por coordenadas)

En lugar de usar una tasa global, se adapta una tasa independiente para cada parámetro (peso) según la historia de sus gradientes. Este principio subyace en algoritmos como AdaGrad, RMSprop y Adam.

Formulación de AdaGrad. Sea $g_{t,i}$ el gradiente del parámetro i en la época t . Se acumula el cuadrado del gradiente:

$$G_{t,i} = G_{t-1,i} + g_{t,i}^2, \quad G_{0,i} = 0, \quad (3)$$

y la actualización del peso w_i es:

$$w_{t+1,i} = w_{t,i} - \frac{\eta}{\sqrt{G_{t,i} + \varepsilon}} g_{t,i}, \quad \varepsilon \approx 10^{-8}. \quad (4)$$

Parámetros con gradientes históricamente grandes reciben una tasa efectiva menor; parámetros con gradientes pequeños mantienen una tasa mayor, favoreciendo la convergencia en direcciones poco exploradas.

4.3. Heurística 3: Programación cíclica de la tasa de aprendizaje (CLR)

Propuesta por Smith [1], esta heurística varía la tasa de aprendizaje entre un límite inferior $\eta_{\min}$ y uno superior $\eta_{\max}$ de forma periódica, en lugar de monótonamente

decreciente. El ciclo puede ser triangular, sinusoidal o exponencial.

Formulación triangular. Para un ciclo de longitud T :

$$\eta(t) = \eta_{\min} + (\eta_{\max} - \eta_{\min}) \cdot \max\left(0, 1 - \left\lfloor \frac{t}{T/2} - 1 \right\rfloor\right). \quad (5)$$

Esta programación ayuda a escapar de mínimos locales y valles de pérdida planos, acelerando la convergencia final.




Figura 1: Comportamiento de tres heurísticas para la tasa de aprendizaje durante 100 épocas.

La figura 1 ilustra cómo cada estrategia modifica la tasa a lo largo del entrenamiento. La elección depende del problema, pero en la práctica combinaciones como *Adam con warm-up* o *SGD con momentum + step decay* son estándares robustos.

5. Actividad 5: Diagrama de dispersión y clustering

El análisis de grupos o *clustering* busca descubrir estructuras latentes en los datos sin supervisión previa. El diagrama de dispersión (*scatter plot*) es una herramienta exploratoria esencial porque permite visualizar la distribución espacial de las observaciones y, en muchos casos, identificar visualmente la existencia de conglomerados naturales.

5.1. Principio de funcionamiento

En un espacio de características de baja dimensionalidad (2D o 3D), los puntos que pertenecen al mismo cluster tienden a agruparse en regiones densas del espacio. El diagrama de dispersión revela:

- **Número tentativo de clusters:** regiones densas y separadas sugieren k grupos.
- **Forma de los clusters:** esféricos, elongados, cóncavos o con ruido de fondo.

- **Valores atípicos:** puntos aislados lejos de cualquier conglomerado.
- **Sobrelapamiento:** clusters que comparten fronteras difusas, lo que indica que algoritmos rígidos como k -means pueden fallar.

5.2. Ejemplo ilustrativo

Considere un conjunto de datos bidimensional que representa las compras semanales de clientes en un supermercado: eje $X = frecuencia\ de\ visitas$ y eje $Y = gasto\ promedio\ por\ visita$. La figura 2 muestra tres patrones diferenciados.




Figura 2: Diagrama de dispersión de clientes según frecuencia de visita y gasto promedio. Se aprecian tres grupos bien diferenciados y un valor atípico (outlier).

5.3. Uso del diagrama para seleccionar algoritmos

Patrón visual	Algoritmo recomendado	Justificación
Esféricos, bien separados	k -means	Minimiza varianza intra-cluster
Formas arbitrarias, densidad	DBSCAN	No asume geometría global
Jerarquía anidada	Clustering jerárquico	Dendrograma muestra niveles
Clusters de densidad variable	HDBSCAN	Robustez a densidades mixtas

Tabla 1: Correspondencia entre patrones visuales en el diagrama de dispersión y algoritmos de clustering.

La tabla 1 resume cómo la morfología observada en el diagrama de dispersión orienta la selección del método de agrupación. En el ejemplo de la figura 2, los tres grupos son aproximadamente esféricos y separados; por tanto, k -means con $k = 3$ sería una elección apropiada.

6. Actividad 6: Clustering para detección de anomalías

La detección de valores anómalos (*outliers* o *anomalies*) es una tarea crítica en analítica de datos, con aplicaciones en detección de fraude, mantenimiento predictivo y seguridad de redes. El análisis de grupos proporciona un marco no supervisado para identificar anomalías sin requerir ejemplos etiquetados de comportamiento anómalo.

6.1. Fundamento teórico

La premisa fundamental es que los datos normales forman conglomerados densos y coherentes, mientras que las anomalías son puntos que no encajan en ningún cluster o que residen en regiones de muy baja densidad. Formalmente, sea $\mathcal{D} = \{\mathbf{x}_1, \dots, \mathbf{x}_n\} \subset \mathbb{R}^d$ y sea $\mathcal{C} = \{C_1, \dots, C_k\}$ una partición obtenida por un algoritmo de clustering. Se definen dos criterios de anomalía [2]:

1. **Distancia al centroide más cercano:** un punto $\mathbf{x}$ es anómalo si

$$\min_{C_j \in \mathcal{C}} \text{dist}(\mathbf{x}, \boldsymbol{\mu}_j) > \theta, \quad (6)$$

donde μ_j es el centroide del cluster C_j y θ es un umbral predefinido.

2. **Densidad local:** en métodos basados en densidad (DBSCAN, HDBSCAN), los puntos clasificados como *ruido* (label = -1) son directamente anómalos.

6.2. Enfoque práctico: Clustering + umbral de distancia

El procedimiento habitual consta de tres etapas:

1. **Agrupar** los datos con un algoritmo adecuado (por ejemplo, k -means).
2. **Calcular** para cada punto su distancia al centroide de su cluster asignado.
3. **Marcar** como anómalo todo punto cuya distancia exceda un percentil alto (típicamente el percentil 95 o 99) de la distribución de distancias.




Figura 3: Detección de anomalías mediante clustering y umbral de distancia. Los puntos rojos quedan fuera del radio de tolerancia del cluster más cercano.

6.3. Ventajas y limitaciones

Ventajas:

- No requiere datos etiquetados; es completamente no supervisado.
- Puede adaptarse a distribuciones de datos complejas mediante clustering de densidad.
- Es interpretable: la anomalía se explica por su alejamiento de los centroides o baja densidad local.

Limitaciones:

- Sensibilidad a la elección del número de clusters (k) o del umbral de densidad (ε en DBSCAN).
- Si las anomalías forman un cluster propio, pueden pasar inadvertidas.
- En alta dimensionalidad la maldición de la dimensionalidad distorsiona las distancias y hace necesario reducir dimensionalidad previamente (PCA, t-SNE, UMAP).

En la práctica, el análisis de grupos para detección de anomalías se complementa con técnicas de aprendizaje profundo como *autoencoders*, que aprenden una representación comprimida de los datos normales y detectan anomalías por alto error de reconstrucción [3].

7. Actividad 7: Métodos jerárquicos en análisis de grupos

Pendiente de completar

Plantee un ejemplo para describir los métodos jerárquicos empleados en el análisis de grupos.

8. Actividad 8: SOM (Kohonen) vs ART2

Pendiente de completar

¿Qué diferencias hay entre los mapas auto-organizativos de Kohonen (SOM) y la red ART2? Explique con ejemplos.

9. Actividad 9: Agrupación incremental

Pendiente de completar

Consulte y plantee un ejemplo sobre agrupación incremental.

10. Actividad 10: Distancias de similitud para agrupación

Pendiente de completar

Describa las distancias: euclidiana, Manhattan, supremo, Canberra, binaria, Mahalanobis y Hamming; proponga el modelo matemático y un ejemplo para cada una.

Bibliografía

Referencias

- [1] Smith, L. N. (2017). Cyclical learning rates for training neural networks. *2017 IEEE Winter Conference on Applications of Computer Vision (WACV)*, 464–472. <https://doi.org/10.1109/WACV.2017.58>
- [2] Chandola, V., Banerjee, A., & Kumar, V. (2009). Anomaly detection: A survey. *ACM Computing Surveys*, 41(3), 1–58. <https://doi.org/10.1145/1541880.1541882>
- [3] Chalapathy, R., & Chawla, S. (2019). Deep learning for anomaly detection: A survey. *arXiv preprint arXiv:1901.03407*. <https://arxiv.org/abs/1901.03407>
- [4] Ester, M., Kriegel, H.-P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. *Proceedings of the 2nd International Conference on Knowledge Discovery and Data Mining (KDD'96)*, 226–231.
- [5] MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, 1, 281–297.
- [6] Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature*, 323(6088), 533–536. <https://doi.org/10.1038/323533a0>
- [7] Xu, R., & Wunsch, D. (2005). Survey of clustering algorithms. *IEEE Transactions on Neural Networks*, 16(3), 645–678. <https://doi.org/10.1109/TNN.2005.845141>