



UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS

Evaluación comparativa de clasificadores de machine learning para la detección de cáncer de mama

Carlos Mora, Juan Felipe Rodríguez, Sergio Duarte

Universidad Distrital Francisco José de Caldas – Analítica de Datos

Mayo 2026



MAESTRÍA EN CIENCIAS DE LA INFORMACIÓN Y LAS COMUNICACIONES

30 AÑOS

- ▶ **Introducción**
- ▶ Problemática
- ▶ Objetivos
- ▶ Dataset
- ▶ Metodología
- ▶ Selección de Atributos
- ▶ Métrica Principal
- ▶ Modelos Implementados
- ▶ Resultados Comparativos
- ▶ Estabilidad y Generalización
- ▶ Discusión y Conclusiones


El problema

- Cáncer de mama: el más frecuente a nivel mundial.
- Principal causa de muerte oncológica en mujeres.
- **Supervivencia >90 %** si se detecta en estadios tempranos.

La oportunidad

- ML clasifica muestras celulares con resultados comparables o superiores a especialistas.
- La clasificación bayesiana permite cuantificar probabilidades de diagnóstico.

Cáncer de mama a nivel global — Año 2020
(Fuente: GLOBOCAN / Sung et al., 2021)



El diagnóstico actual tiene grietas

La efectividad de los modelos depende del flujo completo:

- **Selección de atributos** – ¿qué variables realmente importan?
- **Normalización** – ¿las escalas afectan el modelo?
- **Métricas adecuadas** – ¿accuracy basta en medicina?

Este trabajo: un flujo integrado de analítica de datos evaluando **9 clasificadores** con métricas clínicamente relevantes.

- ▶ Introducción
- ▶ **Problemática**
- ▶ Objetivos
- ▶ Dataset
- ▶ Metodología
- ▶ Selección de Atributos
- ▶ Métrica Principal
- ▶ Modelos Implementados
- ▶ Resultados Comparativos
- ▶ Estabilidad y Generalización
- ▶ Discusión y Conclusiones

¿Por qué esto importa?

Cifras 2020 (GLOBOCAN)

- 2.3 millones de nuevos casos
- 685,000 muertes
- Colombia: 140,000+ casos prevalentes
- 4,322 defunciones en 2023

Falso Negativo

Tumor maligno como benigno → **no tratar** a quien lo necesita.

El diagnóstico por FNA

Depende de la **evaluación subjetiva** del patólogo.

Tasa de discordancia inter-observador:
15–20 % en casos limítrofes.

Falso Positivo

Tumor benigno como maligno → exámenes innecesarios y ansiedad.

- ▶ Introducción
- ▶ Problemática
- ▶ **Objetivos**
- ▶ Dataset
- ▶ Metodología
- ▶ Selección de Atributos
- ▶ Métrica Principal
- ▶ Modelos Implementados
- ▶ Resultados Comparativos
- ▶ Estabilidad y Generalización
- ▶ Discusión y Conclusiones

Objetivo General

Implementar un flujo de analítica de datos para la clasificación de tumores mamarios, evaluando nueve clasificadores de Machine Learning sobre el dataset WDBC con el **Recall de la clase Maligno** como métrica principal.

Objetivos Específicos

1. Preprocesamiento riguroso: detección de anómalos, normalización, selección de atributos.
2. Comparar 9 clasificadores bajo condiciones experimentales idénticas.
3. Analizar estabilidad mediante validación cruzada 5-fold.

- ▶ Introducción
- ▶ Problemática
- ▶ Objetivos
- ▶ **Dataset**
- ▶ Metodología
- ▶ Selección de Atributos
- ▶ Métrica Principal
- ▶ Modelos Implementados
- ▶ Resultados Comparativos
- ▶ Estabilidad y Generalización
- ▶ Discusión y Conclusiones

Características

- **569 instancias:** 357 benignas (62.7 %) y 212 malignas (37.3 %)
- **30 características numéricas continuas**
- Calculadas a partir de imágenes FNA
- Variable objetivo: Maligno (1) / Benigno (0)
- **Sin valores faltantes**




Figura: Distribución de clases en WDBC

Trampa del accuracy

Un clasificador que siempre prediga “benigno” obtendría 62.7 % de exactitud **sin detectar ningún tumor maligno.**

- ▶ Introducción
- ▶ Problemática
- ▶ Objetivos
- ▶ Dataset
- ▶ **Metodología**
 - ▶ Selección de Atributos
 - ▶ Métrica Principal
 - ▶ Modelos Implementados
 - ▶ Resultados Comparativos
 - ▶ Estabilidad y Generalización
 - ▶ Discusión y Conclusiones

Fase	Descripción
1. EDA	Análisis Exploratorio de Datos
2. Preprocesamiento	Detección de anómalos, normalización z-score
3. Selección de atributos	Intersección de 2 métodos
4. División de datos	75 % entrenamiento / 25 % prueba
5. Modelado	9 clasificadores ML
6. Evaluación	Recall Maligno como métrica principal

Mapa de correlación

Se identifican **bloques de alta correlación** entre las versiones *mean*, *error* y *worst* de los mismos atributos.

Implicación: redundancia que justifica selección de atributos.

Distribuciones por clase

- mean area, mean concavity: alta separación
- mean texture: considerable solapamiento




Figura: Mapa de correlación (30 características)

Distribuciones de características clave




Figura: Distribución de características clave por clase. Menor solapamiento = mayor poder discriminativo.

Detección de valores anómalos

Regla de tres sigma: $\mu \pm 3\sigma$

- 74 instancias detectadas (13 %)
- **Decisión: se conservan** – son mediciones clínicas válidas
- Eliminarlos sesgaría el modelo contra tumores atípicos

Normalización z-score

$$z = \frac{x - \mu}{\sigma}$$

- Escalador ajustado **únicamente** en entrenamiento
- Evita *data leakage*
- Indispensable para SVM y KNN

- ▶ Introducción
- ▶ Problemática
- ▶ Objetivos
- ▶ Dataset
- ▶ Metodología
- ▶ **Selección de Atributos**
- ▶ Métrica Principal
- ▶ Modelos Implementados
- ▶ Resultados Comparativos
- ▶ Estabilidad y Generalización
- ▶ Discusión y Conclusiones

Técnica 1: Correlación con la variable objetivo

$|r| \geq 0,50 \rightarrow 16$ características

Técnica 2: Separación de medias

$TEST = \frac{|\bar{x}_B - \bar{x}_M|}{SE(A-B)} \geq 3,0 \rightarrow 16$ características

Resultado

Intersección: 15 características (reducción del 50 %)

Un atributo es relevante *solo* si pasa **ambos** filtros.

Visualización de los métodos




Figura: Correlación con la variable objetivo




Figura: Prueba de separación de medias

15 características seleccionadas

#	Característica	#	Característica
1	area error	9	radius error
2	mean area	10	worst area
3	mean compactness	11	worst compactness
4	mean concave points	12	worst concave points
5	mean concavity	13	worst concavity
6	mean perimeter	14	worst perimeter
7	mean radius	15	worst radius
8	perimeter error		

Descartadas: texture, smoothness, symmetry, fractal dimension (menor poder discriminativo, confirmado por el EDA).

- ▶ Introducción
- ▶ Problemática
- ▶ Objetivos
- ▶ Dataset
- ▶ Metodología
- ▶ Selección de Atributos
- ▶ **Métrica Principal**
- ▶ Modelos Implementados
- ▶ Resultados Comparativos
- ▶ Estabilidad y Generalización
- ▶ Discusión y Conclusiones

Definición

$$\text{Recall Maligno} = \frac{TP}{TP + FN}$$

Sensibilidad: ¿qué fracción de tumores malignos detectamos?

¿Por qué esta métrica?

- **FN:** tumor maligno como benigno → **no tratar**
- **FP:** tumor benigno como maligno → exámenes adicionales
- El riesgo del FN es **sustancialmente mayor**
- Todas las decisiones de hiperparámetros se optimizaron sobre este Recall

- ▶ Introducción
- ▶ Problemática
- ▶ Objetivos
- ▶ Dataset
- ▶ Metodología
- ▶ Selección de Atributos
- ▶ Métrica Principal
- ▶ **Modelos Implementados**
- ▶ Resultados Comparativos
- ▶ Estabilidad y Generalización
- ▶ Discusión y Conclusiones

Los 9 clasificadores evaluados

- SVM (kernel lineal)
- Regresión Logística
- Árbol de Decisión
- Random Forest (100 árboles)
- KNN
- Naive Bayes Gaussiano
- XGBoost
- AdaBoost
- ANN (3 capas densas)

Condiciones experimentales idénticas

- Mismas 15 características seleccionadas
- Mismo conjunto de prueba (143 instancias)
- Implementación en scikit-learn y Keras/TensorFlow

Resultados

- **Exactitud:** 97.90 %
- **Precisión Maligno:** 1.000 (cero falsos positivos)
- **Recall Maligno:** 0.9434 – **mejor del experimento**
- Falsos negativos: solo 3 de 53

CV Recall = $0,899 \pm 0,012$ (estable)

Coeficientes interpretables que permiten auditar cada decisión clínica.




Figura: Matriz de confusión – RL

Resultados

- Exactitud: 96.5 %
- Precisión Maligno: 0.980
- **Recall Maligno: 0.925 – 2° mejor**
- Falsos negativos: 4

CV Recall = $0,893 \pm 0,046$ (mayor varianza)




Figura: Matriz de confusión – XGBoost

Métricas idénticas

- Exactitud: 96.5 %
- Precisión Maligno: 1.000
- Recall Maligno: 0.906
- Cero falsos positivos

Diferencia clave: estabilidad

- Random Forest: $CV\ 0,918 \pm 0,015$ – **más estable**
- SVM: $CV\ 0,893 \pm 0,046$ – mayor varianza

Matriz de Confusión – Random Forest

True label	Predicted label	
	Benigno	Maligno
Benigno	90	0
Maligno	5	48

Figura: Matriz – Random Forest

Random Forest – Importancia de características

Cuatro atributos dominantes

- worst perimeter
- worst area
- worst concave points
- worst radius

Concentran el 56.2 % del poder predictivo total.

La morfología más extrema de las células es el factor más discriminativo.




Figura: Importancia Gini – Random Forest

KNN ($k=1$)

- Exactitud: 90.9 %
- Recall Maligno: 0.849
- FP: 5 (mayor cantidad del experimento)
- Muy sensible al ruido con $k = 1$

Naive Bayes Gaussiano

- Exactitud: 93.7 %
- Recall Maligno: 0.849
- CV Recall: $0,880 \pm 0,013$ – **más estable**
- Conservador: favorece especificidad sobre sensibilidad

AdaBoost

- Exactitud: 94.4 %
- Recall Maligno: 0.868
- 7 falsos negativos
- CV Recall: $0,893 \pm 0,031$

Árbol de Decisión

- Exactitud: 92.3 %
- Recall Maligno: **0.830 – más bajo**
- **Ventaja:** máxima interpretabilidad
- Reglas SI-ENTONCES auditables por médicos

Red Neuronal Artificial (ANN)

Arquitectura

- 3 capas densas (16-16-1)
- 545 parámetros entrenables
- Dropout 20 % + Early Stopping

Resultados

- Exactitud: 96.5 %
- Precisión Maligno: 1.000
- Recall Maligno: 0.906

Sorpresa: no supera a modelos lineales. El problema es linealmente separable.




Figura: Curvas de entrenamiento ANN

- ▶ Introducción
- ▶ Problemática
- ▶ Objetivos
- ▶ Dataset
- ▶ Metodología
- ▶ Selección de Atributos
- ▶ Métrica Principal
- ▶ Modelos Implementados
- ▶ **Resultados Comparativos**
- ▶ Estabilidad y Generalización
- ▶ Discusión y Conclusiones

Ranking por Recall Maligno

Posiciones

1. **Reg. Logística: 0.9434**
2. XGBoost: 0.9245
3. SVM, ANN, RF: 0.9057
4. AdaBoost: 0.8679
5. Naive Bayes, KNN: 0.8491
6. Árbol Decisión: 0.8302




Figura: Comparación visual de métricas




Figura: Curvas ROC para 7 modelos evaluados

AUC = probabilidad de que el modelo asigne mayor score a un maligno que a un benigno.

Tabla comparativa completa

Modelo	Exactitud	Prec. M.	Recall M.	F1 M.
Reg. Logística	0.979	1.000	0.943	0.971
XGBoost	0.965	0.980	0.925	0.952
SVM	0.965	1.000	0.906	0.951
ANN	0.965	1.000	0.906	0.951
Random Forest	0.965	1.000	0.906	0.951
AdaBoost	0.944	0.979	0.868	0.920
Naive Bayes	0.937	0.978	0.849	0.909
KNN	0.909	0.900	0.849	0.874
Árbol Dec.	0.923	0.957	0.830	0.889

Verde = mejor valor Rosa = peor valor por columna

- ▶ Introducción
- ▶ Problemática
- ▶ Objetivos
- ▶ Dataset
- ▶ Metodología
- ▶ Selección de Atributos
- ▶ Métrica Principal
- ▶ Modelos Implementados
- ▶ Resultados Comparativos
- ▶ **Estabilidad y Generalización**
- ▶ Discusión y Conclusiones

Validación cruzada 5-fold

Modelo	Recall (prueba)	CV media	CV $\pm$ std
Reg. Logística	0.943	0.931	0.025
Random Forest	0.906	0.918	0.015
XGBoost	0.925	0.893	0.046
SVM	0.906	0.893	0.046
AdaBoost	0.868	0.893	0.031
Naive Bayes	0.849	0.880	0.013
KNN	0.849	0.899	0.025
Árbol Dec.	0.830	0.855	0.039

Insight clave

SVM y Random Forest tienen **mismas métricas puntuales**, pero RF es 3 veces más estable en CV. La evaluación sobre un solo split habría ocultado esta diferencia.

1. Alta sensibilidad, alta estabilidad

Regresión Logística – mejor Recall (0.943) con desviación moderada (± 0.025). El problema es linealmente separable.

2. Alta sensibilidad, alta varianza

XGBoost – segundo mejor Recall (0.925) pero mayor desviación (± 0.046). Riesgo en datasets pequeños.

3. Menor sensibilidad, mayor estabilidad

Naive Bayes (± 0.013) y **Random Forest** (± 0.015). Predicciones altamente consistentes entre particiones.

- ▶ **Introducción**
- ▶ **Problemática**
- ▶ **Objetivos**
- ▶ **Dataset**
- ▶ **Metodología**
- ▶ **Selección de Atributos**
- ▶ **Métrica Principal**
- ▶ **Modelos Implementados**
- ▶ **Resultados Comparativos**
- ▶ **Estabilidad y Generalización**
- ▶ **Discusión y Conclusiones**

Sobre el flujo

- **EDA:** identificó redundancia entre versiones mean/error/worst
- **Normalización z-score:** indispensable para SVM y KNN
- **Selección:** reducción 50 % (30→15) sin pérdida de rendimiento
- **Recall Maligno:** la métrica correcta para el contexto clínico

Sobre los modelos

- **Regresión Logística:** mejor modelo global (Recall 0.943, precisión perfecta)
- El problema es **linealmente separable** con las 15 características
- Modelos complejos (ANN, RF) **no superaron** a modelos lineales
- La **validación cruzada** distingue modelos con igual rendimiento puntual

Screening masivo

Regresión Logística – mayor Recall, coeficientes interpretables, cero falsos positivos.

Segunda opinión clínica

Random Forest – mejor estabilidad en CV (± 0.015) con rendimiento competitivo.

Comunicación de riesgo

Naive Bayes – probabilidades posteriores explícitas $P(\text{Maligno}|\mathbf{x})$, mayor consistencia.

Validación médica

Árbol de Decisión – reglas SI-ENTONCES auditables, a costa del menor Recall.

1. La **exactitud es insuficiente** en problemas médicos con desbalance de clases.
2. KNN: 90.9 % accuracy pero solo 84.91 % Recall Maligno – **8 tumores malignos sin detectar.**
3. La analítica de datos es un **proceso integrado**: preprocesamiento es tan determinante como el algoritmo.
4. La **validación cruzada** permite distinguir modelos con igual rendimiento puntual pero diferente estabilidad.
5. Que un modelo lineal supere a una red neuronal de 545 parámetros confirma que **la complejidad no garantiza mejor rendimiento.**

- Dataset de un único centro médico – limita generalización a otras poblaciones.
- Tamaño reducido (569 instancias) – insuficiente para arquitecturas de deep learning más complejas.
- No incorpora factores de riesgo clínicos (edad, historial familiar, marcadores genéticos).
- Validación interna (train/test) – se requiere validación externa sobre dataset independiente.
- ANN no incluida en validación cruzada por costo computacional.

Regresión Logística obtuvo el mejor Recall Maligno (94.34 %) con precisión perfecta (1.000) y cero falsos positivos.

El flujo integrado de analítica de datos demuestra que **preprocesamiento + métricas correctas + validación robusta** son tan importantes como el algoritmo de clasificación.

